

Atividade

Preparação do Espaço de Busca

O primeiro passo é definir os documentos que serão indexados. Em Python, você pode representá-los como um dicionário ou uma lista de strings.

- [] Crie um conjunto de documentos de teste (ex: **doc1**, **doc2**, **doc3**).
- [] Atribua um identificador único (ID) para cada documento.

Construção do Vocabulário e Ocorrências Básicas

O vocabulário é o conjunto de palavras únicas da coleção.

- [] Implemente uma função que percorra cada documento e extraia as palavras.
- [] Use um dicionário Python onde a **chave** é a palavra e o **valor** é uma lista de IDs dos documentos onde ela aparece.

Implementação da Lista Invertida Completa

Para permitir buscas mais precisas (como frases exatas), você deve armazenar a posição da palavra e sua frequência.

- [] Registre a quantidade de vezes que o termo aparece no documento e a posição.

Desenvolvimento do Mecanismo de Busca

A busca consiste em localizar o termo no índice e retornar os documentos associados.

- [] **Busca Simples:** Retorne a lista de documentos para uma única palavra.
- [] **Busca Conjuntiva (AND):** Implemente a interseção de listas para encontrar documentos que contenham todos os termos buscados.
- [] **Busca Disjuntiva (OR):** Implemente a união de listas para termos alternativos.

Otimização e Refinamento

O uso de listas invertidas pode ocupar entre 40% a 80% do tamanho do texto original.

- [] **Stop Words:** Implemente um filtro para ignorar palavras irrelevantes (como "o", "a", "de"), reduzindo o espaço necessário.
- [] **Normalização:** Converta todas as palavras para minúsculas e remova pontuações para garantir que "Dados" e "dados" sejam o mesmo índice.